

Analisis dan Prediksi Keberhasilan Akademik Siswa dan Identifikasi Pola Belajar Menggunakan Teknik Machine Learning

Putri Anggraeni¹, Agia Nariswari Wardhana²

^{1,2}Afiliasi (Sistem Informasi, Universitas Negeri Surabaya)

¹24051214028@mhs.unesa.ac.id

²24051214028@mhs.unesa.ac.id

Abstrak— Pendidikan merupakan salah satu faktor penting dalam meningkatkan kualitas sumber daya manusia, sehingga diperlukan analisis untuk memahami faktor-faktor yang mempengaruhi prestasi belajar siswa. Dataset *Student Performance Factors* digunakan untuk mengkaji hubungan antara berbagai variabel seperti jam belajar, kehadiran, nilai sebelumnya, serta faktor lingkungan dan sosial terhadap tingkat prestasi siswa. Penelitian ini bertujuan untuk mengklasifikasikan performa siswa ke dalam kategori *Low*, *Medium*, dan *High* menggunakan metode *machine learning*. Algoritma yang digunakan meliputi *Logistic Regression*, *Random Forest*, dan *XGBoost* dengan tahapan *preprocessing* data seperti pembersihan data, *encoding* variabel kategorikal, dan *standardisasi* fitur. Hasil pengujian menunjukkan bahwa model *XGBoost* memberikan performa terbaik dengan akurasi sebesar 87,59% dibandingkan algoritma lainnya. Selain itu, dilakukan analisis tambahan menggunakan *K-Means Clustering* untuk mengelompokkan pola siswa berdasarkan karakteristik yang dimiliki. Penelitian ini juga menerapkan *Explainable Artificial Intelligence* (XAI) menggunakan *SHAP* untuk menjelaskan faktor-faktor yang mempengaruhi prediksi model. Model terbaik kemudian diimplementasikan ke dalam aplikasi web berbasis *Streamlit* sehingga dapat digunakan untuk analisis dan prediksi performa akademik siswa secara interaktif

Kata Kunci— pendidikan, *student performance*, *machine learning*, *XGBoost*, *K-Means Clustering*, klasifikasi.

I. PENDAHULUAN

Pendidikan merupakan proses pembentukan individu yang bersifat intelektual dan sosial yang bertujuan untuk mengembangkan potensi manusia secara menyeluruh, tidak hanya dalam hal pengetahuan tetapi juga pembentukan sikap dan kepribadian. Pendidikan tidak hanya berfokus pada transfer ilmu dan keterampilan, tetapi juga pada transformasi nilai dan pembentukan karakter. Melalui pendidikan, manusia dibekali kemampuan untuk menghadapi perkembangan zaman serta mewariskan nilai, budaya, dan pengetahuan kepada generasi berikutnya agar siap menghadapi tantangan masa depan [1].

Pendidikan memiliki peran penting dalam meningkatkan kualitas sumber daya manusia. Seiring dengan perkembangan teknologi informasi, data pendidikan dapat dimanfaatkan untuk membantu memahami faktor-faktor yang mempengaruhi keberhasilan akademik siswa. Melalui pendekatan *machine learning*, data akademik dapat digunakan untuk memprediksi tingkat performa siswa, mengidentifikasi faktor-faktor yang berpengaruh terhadap hasil belajar, mengelompokkan siswa berdasarkan karakteristik yang

serupa, serta mendukung pengambilan keputusan berbasis data di bidang pendidikan

Perkembangan teknologi informasi pada era digital saat ini telah memberikan dampak signifikan terhadap dunia pendidikan, khususnya dalam pemanfaatan data untuk menganalisis dan meningkatkan kualitas pembelajaran. Salah satu pendekatan yang banyak digunakan adalah *machine learning*, yang memungkinkan sistem untuk mempelajari pola dari data historis dan menghasilkan prediksi secara otomatis. Dalam konteks pendidikan, pendekatan ini dapat diterapkan untuk menganalisis *student performance* berdasarkan data akademik siswa.

Dataset *Student Performance* yang diperoleh dari *Kaggle* memuat berbagai atribut yang menggambarkan kondisi akademik dan aktivitas belajar siswa, yang dapat digunakan untuk memprediksi hasil akhir atau performa akademik siswa [2]. Data ini menjadi penting dalam membantu institusi pendidikan untuk memahami faktor-faktor yang mempengaruhi keberhasilan belajar serta mengidentifikasi siswa yang membutuhkan perhatian lebih lanjut.

Beberapa penelitian menunjukkan bahwa algoritma *machine learning* seperti *Random Forest* dan *XGBoost* memiliki kemampuan yang baik dalam melakukan prediksi performa siswa dengan tingkat akurasi yang tinggi [3]. Selain itu, metode berbasis *ensemble learning* seperti *XGBoost* terbukti memiliki kinerja yang lebih baik dibandingkan metode *boosting* lainnya dalam berbagai kasus klasifikasi karena mampu meningkatkan akurasi dan mengurangi *error* prediksi [4].

Penelitian terdahulu juga menunjukkan bahwa pendekatan *data mining* dapat digunakan secara efektif dalam memprediksi performa siswa dengan memanfaatkan data akademik dan faktor pendukung lainnya. Pendekatan ini terbukti mampu memberikan hasil prediksi yang akurat sehingga dapat digunakan sebagai dasar pengambilan keputusan dalam dunia pendidikan [5].

Selain itu, algoritma seperti *XGBoost* telah banyak digunakan dalam berbagai penelitian karena memiliki kemampuan optimasi yang tinggi dalam menangani data tabular dan mampu menghasilkan performa klasifikasi yang lebih baik dibandingkan metode *boosting* konvensional [6]. Penelitian lain juga menunjukkan bahwa metode *Random Forest* masih efektif digunakan sebagai algoritma pembanding dalam klasifikasi data pendidikan karena memiliki kemampuan generalisasi yang baik pada dataset kecil maupun besar [7].

Berdasarkan hal tersebut, penelitian ini bertujuan untuk menerapkan metode *machine learning* khususnya *XGBoost*, *Random Forest*, dalam melakukan klasifikasi *student performance* berdasarkan dataset *Kaggle* [2]. Metode klasifikasi yang digunakan adalah *XGBoost* dan *Random Forest* untuk memprediksi tingkat performa akademik siswa, sedangkan metode *K-Means Clustering* digunakan untuk mengelompokkan siswa berdasarkan karakteristik yang dimiliki. Selain membandingkan performa model klasifikasi yang digunakan, penelitian ini juga bertujuan mengidentifikasi faktor-faktor yang paling berpengaruh terhadap hasil akademik siswa. Hasil penelitian diharapkan dapat memberikan informasi yang bermanfaat bagi institusi pendidikan dalam melakukan evaluasi pembelajaran, mengidentifikasi karakteristik siswa, serta mendukung pengambilan keputusan yang lebih efektif berbasis data

II. TINJAUAN PUSTAKA

A. Pendidikan

Pendidikan merupakan suatu upaya yang dilakukan oleh individu maupun kelompok untuk membantu seseorang mencapai kedewasaan serta mengembangkan potensi yang dimilikinya. Pendidikan berperan penting sebagai sarana dalam meningkatkan kemampuan berpikir dan pemahaman melalui proses pembelajaran dan pengajaran. Selain itu, pendidikan juga memiliki fungsi dalam membentuk karakter individu, sehingga seseorang mampu bertindak, berpikir, serta mengambil keputusan dengan lebih baik dan bijaksana [8].

B. Machine Learning

Machine Learning merupakan sekumpulan metode yang digunakan untuk mengolah dan memprediksi data dalam jumlah besar dan beragam menggunakan algoritma pembelajaran tertentu [9]. Dalam penelitian ini, *machine learning* diterapkan pada dataset *Student Performance* yang diperoleh dari *Kaggle* untuk menganalisa dan memprediksi hasil atau tingkat performa siswa berdasarkan atribut yang tersedia pada data. Hal ini membantu dalam proses analisis data pendidikan menjadi lebih cepat dan efisien. Tujuan utama dari *machine learning* dalam penelitian ini adalah membangun model yang mampu memprediksi *student performance* berdasarkan pola data yang ada, sehingga dapat membantu dalam mengidentifikasi siswa dengan performa baik maupun siswa yang membutuhkan perhatian lebih lanjut. Proses *machine learning* dalam penelitian ini meliputi beberapa tahapan, yaitu pengumpulan dataset *Student Performance*, *preprocessing* data, pembagian data menjadi data latih dan data uji, pelatihan model menggunakan algoritma seperti *XGBoost*, dan *Random Forest* serta evaluasi model menggunakan metrik seperti *accuracy*, *precision*, *recall*, dan *F1-score*.

C. Student Performance

Student performance merupakan ukuran keberhasilan siswa dalam proses pembelajaran yang umumnya dinilai berdasarkan hasil akademik, nilai ujian, partisipasi belajar, serta berbagai faktor pendukung lainnya. Analisis *student*

performance menjadi salah satu topik penting dalam bidang *Educational Data Mining* karena dapat membantu institusi pendidikan dalam mengidentifikasi siswa yang berpotensi mengalami kesulitan belajar maupun siswa yang memiliki prestasi tinggi. Prediksi performa siswa juga dapat digunakan sebagai dasar dalam pengambilan keputusan akademik dan pemberian intervensi dini untuk meningkatkan hasil belajar siswa [10]. Data akademik siswa dapat dimanfaatkan untuk membangun model prediksi yang mampu memperkirakan hasil belajar siswa berdasarkan karakteristik individu, lingkungan keluarga, dan aktivitas pembelajaran. Pemanfaatan teknik *data mining* dan *machine learning* dalam prediksi *student performance* memungkinkan proses evaluasi dilakukan secara lebih cepat dan akurat dibandingkan metode konvensional [5].

D. Machine Learning dalam Pendidikan

Machine learning merupakan cabang kecerdasan buatan yang memungkinkan sistem komputer mempelajari pola dari data dan menghasilkan prediksi tanpa harus diprogram secara eksplisit. Dalam bidang pendidikan, *machine learning* banyak digunakan untuk memprediksi performa siswa, mengidentifikasi risiko kegagalan akademik, serta membantu proses pengambilan keputusan berbasis data. Algoritma *machine learning* seperti *Random Forest* mampu menghasilkan performa yang baik dalam prediksi hasil akademik siswa. Dengan memanfaatkan data historis siswa, model *machine learning* dapat menemukan pola yang tidak mudah dikenali secara manual sehingga membantu meningkatkan kualitas evaluasi pendidikan [11].

Dalam penelitian ini, penerapan *machine learning* dilakukan untuk memprediksi tingkat performa akademik siswa menggunakan dataset *Student Performance Factors*. Proses klasifikasi dilakukan dengan membandingkan beberapa algoritma, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost*. Hasil prediksi kemudian dievaluasi menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score* untuk menentukan model yang memiliki performa terbaik dalam mengklasifikasikan siswa ke dalam kategori *Low*, *Medium*, dan *High*.

E. Random Forest

Random forest adalah metode *machine learning* yang bekerja dengan menggabungkan beberapa pohon keputusan. Proses ini menghasilkan satu set pohon acak, dimana kelas hasil klasifikasi dipilih dari kelas yang paling populer [12]. Dalam proses ini, *random forest* melakukan penarikan sampel acak berukuran n dengan penggantian pada kelompok data, yang merupakan tahapan *bootstrap*. Dengan menggunakan sampel *bootstrap*, pohon – pohon dibangun hingga mencapai ukuran maksimum. Pada setiap simpul, dilakukan penyaringan dengan memilih m variabel penjelas secara acak, dikenal sebagai *random feature selection* [13].

Random Forest adalah metode *ensemble* yang terdiri dari banyak *decision tree*. Setiap pohon dilatih dengan subset data yang berbeda sehingga menghasilkan prediksi yang lebih stabil. Dalam penelitian ini, *Random Forest* digunakan untuk

menangani data dengan banyak fitur dan mengurangi overfitting.

Dalam penelitian ini, *Random Forest* digunakan sebagai salah satu algoritma klasifikasi untuk memprediksi tingkat performa akademik siswa berdasarkan atribut yang terdapat pada dataset *Student Performance Factors*. Algoritma ini dipilih karena mampu menangani data dengan jumlah fitur yang cukup banyak serta memiliki kemampuan generalisasi yang baik. Hasil klasifikasi menggunakan *Random Forest* kemudian dibandingkan dengan *Logistic Regression* dan *XGBoost* untuk memperoleh model dengan performa terbaik.

F. Streamlit

Streamlit merupakan *open source framework* yang memungkinkan pengembangan aplikasi web berbasis python, khususnya dalam bidang sains data dan *machine learning*. Fitur – fiturnya membantu mempermudah pengembangan model machine learning dengan visualisasi melalui antarmuka interaktif untuk berkomunikasi dengan user. *Streamlit* juga mendukung pembuatan presentasi dan kolaborasi, serta memungkinkan ekspor dokumen dalam format aplikasi data interaktif. Proses eksekusi script python dilakukan dari baris atas hingga bawah setiap kali user berinteraksi dengan aplikasi [15].

Pada penelitian ini, *Streamlit* digunakan untuk mengimplementasikan model terbaik yang diperoleh dari proses klasifikasi ke dalam bentuk aplikasi web interaktif. Aplikasi yang dibangun memiliki beberapa fitur, yaitu *Home*, *Dataset Overview*, *Prediction/Analysis*, *Visualization*, dan *About*. Melalui aplikasi ini, pengguna dapat melakukan prediksi tingkat performa siswa berdasarkan data yang dimasukkan serta melihat visualisasi hasil analisis secara langsung.

G. CRISP-DM

CRISP-DM merupakan sebuah metodologi yang menyediakan pendekatan umum untuk membentuk dan merencanakan proyek data mining [16]. Metodologi ini dirilis pertama kali sekitar 20 tahun yang lalu atau sekitar tahun 2000-an [17]. Hingga saat ini, metodologi ini menjadi metodologi yang paling populer di bidang data science, lebih tepatnya di area data mining. Metodologi ini dapat digunakan baik sebagai metodologi proyek maupun sebagai model proses [17]. Sebagai model proses biasanya digunakan ketika praktek mengolah data atau yang bersifat lebih teknis. Sedangkan sebagai metodologi proyek adalah ketika digunakan dalam hal yang lebih formal seperti penelitian dan melibatkan setiap fase di tahapannya.

Dalam penelitian ini, metodologi *CRISP-DM* digunakan sebagai kerangka kerja utama dalam pengembangan proyek *data mining*. Tahapan yang dilakukan meliputi *Business Understanding* untuk memahami permasalahan prediksi performa siswa, *Data Understanding* untuk mengeksplorasi dataset *Student Performance Factors*, *Data Preparation* untuk melakukan pembersihan dan transformasi data, *Modeling* menggunakan algoritma *Logistic Regression*, *Random Forest*, *XGBoost*, dan *K-Means*

Clustering, *Evaluation* untuk membandingkan performa model, serta *Deployment* dengan mengimplementasikan model terbaik ke dalam aplikasi web berbasis *Streamlit*.

H. Classification

Classification merupakan salah satu teknik dalam *machine learning* yang digunakan untuk mengelompokkan data ke dalam kelas atau kategori tertentu berdasarkan pola yang dipelajari dari data historis. Metode ini termasuk dalam *supervised learning* karena proses pelatihannya menggunakan data yang telah memiliki label [18].

Dalam penelitian ini, *classification* digunakan untuk memprediksi tingkat performa akademik siswa ke dalam kategori *Low*, *Medium*, dan *High* berdasarkan faktor-faktor yang terdapat pada dataset *Student Performance Factors*. Algoritma yang digunakan dalam proses klasifikasi meliputi *Logistic Regression*, *Random Forest*, dan *XGBoost*, kemudian dievaluasi menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score* untuk menentukan model dengan performa terbaik.

I. XGBoost

XGBoost (Extreme Gradient Boosting) merupakan algoritma *machine learning* yang dikembangkan berdasarkan metode *gradient boosting*. Algoritma ini bekerja dengan membangun beberapa *decision tree* secara bertahap, dimana setiap model baru berfungsi untuk memperbaiki kesalahan prediksi dari model sebelumnya. *XGBoost* memiliki keunggulan dalam kecepatan komputasi, kemampuan menangani data berukuran besar, serta dilengkapi dengan teknik regularisasi yang dapat mengurangi risiko *overfitting*. Oleh karena itu, *XGBoost* banyak digunakan dalam berbagai penelitian klasifikasi dan prediksi karena mampu menghasilkan performa yang tinggi [6].

Dalam penelitian ini, *XGBoost* digunakan sebagai salah satu model klasifikasi untuk memprediksi tingkat performa akademik siswa berdasarkan atribut yang terdapat pada dataset *Student Performance Factors*. Hasil pengujian menunjukkan bahwa model *XGBoost* memberikan performa terbaik dengan nilai akurasi sebesar 87,59%.

J. K-Means Clustering

K-Means Clustering merupakan metode *unsupervised learning* yang digunakan untuk mengelompokkan data ke dalam beberapa kelompok (*cluster*) berdasarkan kemiripan karakteristik data. Algoritma ini bekerja dengan menentukan titik pusat kelompok (*centroid*) dan mengelompokkan setiap data ke *cluster* terdekat berdasarkan jarak tertentu [19].

Dalam penelitian ini, *K-Means Clustering* digunakan untuk mengidentifikasi pola dan karakteristik siswa berdasarkan atribut yang terdapat pada dataset *Student Performance Factors*. Hasil pengelompokan dapat memberikan informasi mengenai kelompok siswa yang memiliki karakteristik serupa sehingga dapat membantu institusi pendidikan dalam memahami profil siswa secara lebih baik.

K. Linear Regression

Linear Regression merupakan salah satu algoritma dalam *machine learning* yang digunakan untuk memodelkan hubungan antara variabel independen (fitur) dan variabel dependen (target) dengan pendekatan linear. Algoritma ini termasuk dalam kategori *supervised learning* karena proses pelatihannya menggunakan data yang telah memiliki label [20].

Secara konsep, *Linear Regression* berusaha mencari hubungan terbaik berbentuk garis lurus (*best fit line*) yang dapat menggambarkan hubungan antara fitur input dan hasil output. Model ini memberikan bobot pada setiap variabel independen untuk menunjukkan seberapa besar pengaruhnya terhadap variabel target. Dalam penelitian ini, variabel seperti *Hours Studied*, *Attendance*, dan *Previous Scores* menjadi input utama yang digunakan untuk memprediksi tingkat performa akademik siswa.


Dalam implementasinya, *Linear Regression* bekerja dengan cara meminimalkan error antara nilai prediksi dan nilai aktual menggunakan metode *least squares*. Tujuan utama dari proses ini adalah menghasilkan model dengan kesalahan sekecil mungkin sehingga prediksi yang dihasilkan lebih mendekati nilai sebenarnya.

Dalam penelitian ini, *Linear Regression* tidak digunakan sebagai model utama, tetapi sebagai model pembandingan (*baseline model*). Tujuan penggunaan model ini adalah untuk mengetahui sejauh mana performa model sederhana dalam melakukan prediksi dibandingkan dengan model yang lebih kompleks seperti *Random Forest* dan *XGBoost*.

Selain itu, *Linear Regression* digunakan untuk memberikan gambaran awal mengenai hubungan linear antar variabel dalam dataset *Student Performance Factors*. Misalnya, apakah peningkatan jam belajar (*Hours Studied*) berpengaruh terhadap peningkatan nilai ujian (*Exam Score*), atau apakah tingkat kehadiran (*Attendance*) memiliki korelasi positif terhadap hasil akademik siswa.

III. METODOLOGI PENELITIAN

Penelitian ini menggunakan metodologi *Cross-Industry Standard Process for Data Mining (CRISP-DM)* sebagai kerangka kerja dalam pengembangan proyek *data mining*. Metodologi ini dipilih karena menyediakan tahapan yang sistematis mulai dari pemahaman masalah hingga implementasi model. Tahapan yang dilakukan dalam penelitian ini meliputi *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment*.



Gbr. 1 Flowchart CRISP-DM

A. Business Understanding

Tahap *Business Understanding* bertujuan untuk memahami permasalahan yang akan diselesaikan. Dalam penelitian ini, permasalahan yang diangkat adalah bagaimana memanfaatkan data akademik siswa untuk memprediksi tingkat performa akademik serta mengidentifikasi karakteristik siswa berdasarkan pola yang dimiliki.

Pendidikan memiliki peran penting dalam meningkatkan kualitas sumber daya manusia. Namun, institusi pendidikan sering mengalami kesulitan dalam mengidentifikasi faktor-faktor yang memengaruhi keberhasilan akademik siswa secara cepat dan akurat. Oleh karena itu, diperlukan pendekatan berbasis *machine learning* untuk membantu proses analisis data pendidikan.

Tujuan penelitian ini adalah:

1. Mengklasifikasikan performa siswa ke dalam kategori *Low*, *Medium*, dan *High*.
2. Membandingkan performa algoritma *Logistic Regression*, *Random Forest*, dan *XGBoost*.
3. Mengelompokkan siswa berdasarkan karakteristik yang dimiliki menggunakan metode *K-Means Clustering*.
4. Mengimplementasikan model terbaik ke dalam aplikasi web berbasis *Streamlit*.

B. Data Understanding

Pada tahap *Data Understanding*, dilakukan proses pengumpulan dan eksplorasi data untuk memahami karakteristik dataset yang digunakan. Dataset yang digunakan adalah *Student Performance Factors* yang diperoleh dari platform *Kaggle*. Dataset ini berisi berbagai atribut yang berkaitan dengan performa akademik siswa, seperti: *Hours Studied*, *Attendance*, *Previous Scores*, *Sleep Hours*, *Tutoring Sessions*, *Parental Involvement*, *Internet Access*, *Teacher*

Quality, *School Type*, *Motivation Level*, dan atribut pendukung lainnya.

Informasi Dataset	Nilai
Jumlah Data	6.607
Jumlah Atribut	20
Fitur Numerik	7
Fitur Kategorikal	13
Variabel Target	<i>Exam Score</i>
Kelas Target	<i>Low, Medium, High</i>

Tabel. 1 *Data Understanding*

C. Data Preparation

Tahap *Data Preparation* dilakukan untuk mempersiapkan data sebelum digunakan dalam proses pemodelan. Proses yang dilakukan meliputi:

1. *Pembersihan data*
Pemeriksaan data dilakukan untuk memastikan tidak terdapat data duplikat maupun nilai yang tidak sesuai.
2. *Penanganan Missing Value*
Nilai kosong pada atribut kategorikal diisi menggunakan nilai modus, sedangkan atribut numerik disesuaikan berdasarkan karakteristik data.
3. *Encoding Data Kategorikal*
Variabel kategorikal diubah ke bentuk numerik menggunakan teknik *Label Encoding* agar dapat diproses oleh algoritma *machine learning*.
4. *Feature Scaling*
Data numerik dinormalisasi menggunakan *StandardScaler* untuk menyamakan skala antar fitur sehingga proses pelatihan model menjadi lebih optimal.
5. *Pembentukan Target Klasifikasi*
Nilai akhir siswa dikategorikan menjadi tiga kelas yaitu *Low*, *Medium*, dan *High* berdasarkan rentang nilai yang telah ditentukan.
6. *Pembagian Data*
Dataset dibagi menjadi data latih dan data uji menggunakan rasio 80:20 untuk proses pelatihan dan evaluasi model.

D. Modeling

Tahap *Modeling* dilakukan untuk membangun model klasifikasi dan *clustering*. Proses yang dilakukan meliputi:

1. *Classification*
 - a. *Logistic Regression*
Logistic Regression digunakan sebagai model dasar (*baseline model*) untuk melakukan klasifikasi performa siswa.
 - b. *Random Forest*

Random Forest digunakan karena memiliki kemampuan yang baik dalam menangani data dengan banyak atribut dan mampu mengurangi risiko *overfitting*.

c. XGBoost

XGBoost digunakan karena memiliki performa yang tinggi dalam berbagai permasalahan klasifikasi dan mampu meningkatkan akurasi melalui metode *gradient boosting*.

2. Clustering

Metode *K-Means Clustering* digunakan untuk mengelompokkan siswa berdasarkan karakteristik yang dimiliki. Jumlah *cluster* ditentukan menggunakan metode *Elbow Method* dan *Silhouette Score* dan untuk memperoleh nilai K yang optimal.

E. Evaluation

Tahap *Evaluation* dilakukan untuk mengukur performa model yang telah dibangun. Evaluasi model klasifikasi dilakukan menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*

Selain itu, digunakan *Confusion Matrix* untuk melihat distribusi hasil prediksi pada masing-masing kelas. Berdasarkan hasil pengujian, model *XGBoost* menghasilkan performa terbaik dengan nilai akurasi sebesar 87,59%, sehingga dipilih sebagai model utama untuk implementasi sistem. Untuk metode *K-Means Clustering*, evaluasi dilakukan menggunakan *Elbow Method* dan analisis karakteristik pada setiap *cluster* yang terbentuk.

F. Deployment

Tahap *Deployment* merupakan tahap implementasi model ke dalam aplikasi web menggunakan *Streamlit*. Aplikasi berhasil diimplementasikan menggunakan framework *Streamlit* dan dipublikasikan melalui *Streamlit Community Cloud*. Seluruh kode sumber, model *machine learning*, dataset, dan dokumentasi proyek juga disimpan pada repositori *GitHub* untuk mendukung reproduktibilitas dan pengembangan lebih lanjut. Aplikasi yang dibangun memiliki beberapa halaman utama yaitu:

1. *Home*
2. *Dataset Overview*
3. *Classification*
4. *Clustering*
5. *Explainable AI*
6. *Prediction*
7. *About*

Melalui aplikasi tersebut, pengguna dapat memasukkan data siswa, melakukan prediksi tingkat performa akademik, melihat hasil klasifikasi, serta menampilkan visualisasi data dan hasil analisis secara interaktif. Model *XGBoost* yang memiliki performa terbaik digunakan sebagai model utama dalam proses prediksi pada aplikasi.

IV. HASIL DAN PEMBAHASAN

A. Data Understanding (Pemahaman Dataset)

Dataset yang digunakan dalam penelitian ini adalah *Student Performance Factors* yang diperoleh dari *Kaggle*. Dataset terdiri dari 6.607 data dengan 20 atribut yang menggambarkan berbagai faktor yang memengaruhi performa akademik siswa. Variabel yang digunakan meliputi *Hours Studied*, *Attendance*, *Previous Scores*, *Sleep Hours*, *Tutoring Sessions*, *Physical Activity*, *Motivation Level*, *Internet Access*, *Teacher Quality*, *Family Income*, dan beberapa faktor pendukung lainnya. Variabel target yang digunakan adalah *Exam Score*, yaitu nilai ujian siswa yang menjadi indikator performa akademik. Dataset ini dipilih karena menyediakan informasi yang cukup lengkap mengenai faktor internal maupun eksternal yang dapat memengaruhi hasil belajar siswa.

Berdasarkan hasil eksplorasi data, atribut dalam dataset terdiri dari data numerik dan kategorikal. Data numerik digunakan secara langsung pada proses pemodelan, sedangkan data kategorikal perlu ditransformasikan terlebih dahulu ke bentuk numerik agar dapat diproses oleh algoritma *machine learning*.

B. Preprocessing Data

Pada tahap awal dilakukan pemeriksaan kualitas data untuk mengidentifikasi adanya nilai kosong (*missing value*) pada setiap atribut dataset. Hasil pemeriksaan menunjukkan bahwa beberapa atribut seperti *Teacher Quality*, *Parental Education Level*, dan *Distance from Home* masih memiliki nilai yang belum terisi.

Proses *data cleaning* dilakukan untuk menangani nilai kosong sehingga tidak mengganggu proses pelatihan model. Setelah seluruh data dipastikan lengkap, dilakukan pemisahan atribut fitur dan target. Atribut *Exam Score* digunakan sebagai variabel target, sedangkan atribut lainnya digunakan sebagai variabel prediktor.

Selanjutnya dilakukan transformasi data kategorikal menggunakan metode *Label Encoding* dari library *Scikit-Learn*. Proses ini mengubah data berbentuk teks menjadi representasi numerik sehingga dapat digunakan oleh algoritma *machine learning*.


Setelah proses encoding selesai, dilakukan normalisasi menggunakan *StandardScaler*. Teknik ini digunakan untuk menyamakan skala setiap atribut sehingga tidak terjadi dominasi variabel tertentu yang memiliki rentang nilai lebih besar dibandingkan variabel lainnya. Normalisasi juga membantu meningkatkan stabilitas dan performa model pada proses pelatihan.

C. Analisis Statistik Deskriptif

Analisis statistik deskriptif dilakukan untuk memperoleh gambaran umum mengenai karakteristik dataset yang digunakan. Beberapa variabel utama yang dianalisis meliputi *Hours Studied*, *Attendance*, *Previous Scores*, *Sleep Hours*, *Tutoring Sessions*, dan *Physical Activity*.

Hasil analisis menunjukkan bahwa mayoritas siswa memiliki tingkat kehadiran yang tinggi dan jam belajar yang relatif konsisten. Selain itu, distribusi nilai ujian menunjukkan variasi yang cukup besar sehingga dataset memiliki

keragaman yang baik untuk digunakan dalam proses pembelajaran model *machine learning*. Variasi data yang cukup luas menunjukkan bahwa model memiliki peluang untuk mempelajari pola hubungan antara faktor-faktor akademik dan hasil ujian secara lebih efektif.



Gbr. 3 Exam Score Diagram Distribution of numerical features

D. Analisis Distribusi Data

Visualisasi distribusi digunakan untuk melihat pola penyebaran setiap variabel.

1. Hours Studied

Distribusi jam belajar menunjukkan sebagian besar siswa belajar pada rentang menengah. Hal ini mengindikasikan bahwa mayoritas siswa memiliki kebiasaan belajar yang cukup konsisten.

2. Attendance

Distribusi kehadiran cenderung tinggi. Sebagian besar siswa memiliki tingkat kehadiran di atas rata-rata yang menunjukkan tingkat partisipasi akademik yang baik.

3. Previous Score

Nilai akademik sebelumnya menunjukkan distribusi yang relatif normal. Kondisi ini menandakan bahwa dataset tidak didominasi oleh kelompok siswa tertentu.


4. Exam Score

Distribusi nilai ujian menunjukkan variasi yang cukup lebar sehingga cocok digunakan sebagai dasar analisis performa akademik.

E. Analisis Korelasi Variabel

Analisis korelasi dilakukan menggunakan heatmap korelasi untuk mengetahui hubungan antara setiap variabel dengan nilai ujian siswa. Hasil analisis menunjukkan bahwa variabel *Hours Studied*, *Attendance*, dan *Previous Scores* memiliki hubungan positif terhadap *Exam Score*. Semakin

tinggi intensitas belajar, tingkat kehadiran, dan nilai akademik sebelumnya, maka semakin tinggi pula kecenderungan siswa memperoleh nilai ujian yang baik. Sebaliknya, beberapa variabel menunjukkan korelasi yang relatif rendah terhadap nilai ujian sehingga kontribusinya tidak sebesar faktor akademik utama.



Gbr. 4 Correlation Heatmap Dataset Student Performance

Correlation	
Exam_Score	1.000000
Attendance	0.581072
Hours_Studied	0.445455
Previous_Scores	0.175079
Tutoring_Sessions	0.156525
Physical_Activity	0.027824
Sleep_Hours	-0.017022

Gbr. 5 Correlation Variabel

F. Pengujian Model

Pengujian model *machine learning* dilakukan menggunakan bahasa pemrograman Python melalui platform Google Colab. Dataset yang telah melalui tahap *preprocessing* selanjutnya dibagi menjadi data latih (*training data*) dan data uji (*testing data*) menggunakan metode *train-test split*. Pembagian data dilakukan untuk memastikan model dapat dievaluasi menggunakan data yang belum pernah dilihat sebelumnya sehingga mampu mengukur kemampuan generalisasi model secara objektif.


Pada penelitian ini digunakan tiga algoritma *machine learning*, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost* untuk memprediksi performa akademik siswa berdasarkan faktor-faktor yang terdapat pada dataset. Ketiga algoritma tersebut dipilih karena memiliki karakteristik yang berbeda, sehingga dapat memberikan gambaran mengenai metode yang paling efektif dalam melakukan prediksi terhadap data performa siswa.

Sebelum proses pelatihan model dilakukan, data numerik dinormalisasi menggunakan *StandardScaler* dan data kategorikal ditransformasikan menggunakan *Label Encoding*.

Tahapan ini bertujuan untuk memastikan seluruh atribut berada dalam format yang sesuai dan dapat diproses oleh algoritma *machine learning* secara optimal.

Setelah proses pelatihan selesai, masing-masing model dievaluasi menggunakan beberapa metrik pengukuran kinerja, yaitu *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Penggunaan beberapa metrik evaluasi bertujuan untuk memperoleh gambaran yang lebih komprehensif mengenai kemampuan model dalam melakukan klasifikasi performa akademik siswa.

G. Analisis dan Hasil Evaluasi Classification Logistic Regression



Gbr. 6 Confusion Matrix Logistic Regression

Training Accuracy = 0.8259 (82,59%)

Testing Accuracy = 0.8011 (80,11%).


Model *Logistic Regression* menghasilkan training accuracy sebesar 82,59% dan testing accuracy sebesar 80,11%. Hasil confusion matrix menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar pada ketiga kategori performa siswa, yaitu Low, Medium, dan High. Nilai akurasi yang cukup tinggi menunjukkan bahwa model mampu mengenali pola data dengan baik dalam melakukan klasifikasi performa akademik siswa.

	precision	recall	f1-score	support
Low	0.87	0.86	0.86	577
Medium	0.69	0.72	0.70	420
High	0.83	0.81	0.82	325
accuracy			0.80	1322
macro avg	0.80	0.79	0.80	1322
weighted avg	0.80	0.80	0.80	1322

Gbr. 7 Evaluasi Logistic Regression

Berdasarkan *classification report*, kategori Low memiliki performa terbaik dengan nilai precision sebesar 0,87, recall 0,86, dan F1-score 0,86. Sementara itu, kategori Medium memiliki nilai F1-score terendah yaitu 0,70, sedangkan kategori High memperoleh F1-score sebesar 0,82. Secara keseluruhan model menghasilkan accuracy sebesar 0,80 dengan weighted average F1-score sebesar 0,80.

H. Analisis dan Hasil Evaluasi *Classification Random Forest*



Gbr. 8 *Confusion Matrix Random Forest*

Training Accuracy = 0.9949 (99,49%)

Testing Accuracy = 0.8056 (80,56%).


Model *Random Forest* memperoleh training accuracy sebesar 99,49% dan testing accuracy sebesar 80,56%. Hasil ini menunjukkan bahwa model mampu mempelajari pola data dengan sangat baik pada data latih serta menghasilkan performa yang cukup baik pada data pengujian.

	precision	recall	f1-score	support
Low	0.88	0.87	0.88	577
Medium	0.69	0.73	0.71	420
High	0.84	0.78	0.81	325
accuracy			0.81	1322
macro avg	0.80	0.80	0.80	1322
weighted avg	0.81	0.81	0.81	1322

Gbr. 9 Evaluasi *Random Forest*

Berdasarkan *classification report*, kategori Low memperoleh nilai precision sebesar 0,88, recall 0,87, dan F1-score 0,88. Kategori Medium memperoleh F1-score sebesar 0,71, sedangkan kategori High memperoleh F1-score sebesar 0,81. Secara keseluruhan model menghasilkan accuracy sebesar 0,81 dengan weighted average F1-score sebesar 0,81. Hasil ini menunjukkan bahwa Random Forest sedikit lebih baik dibandingkan Logistic Regression dalam mengklasifikasikan performa siswa.


I. *Random Forest Feature Importance*



Gbr. 10 *Random Forest Feature Importance*

Fitur *Attendance* memiliki nilai feature importance tertinggi dibandingkan fitur lainnya. Hal ini menunjukkan bahwa tingkat kehadiran siswa merupakan faktor yang paling berpengaruh dalam prediksi performa akademik menggunakan model *Random Forest*. Hasil ini juga konsisten dengan analisis *SHAP* pada model *XGBoost*, yang menunjukkan bahwa *Attendance* dan *Hours Studied* merupakan dua faktor yang paling berpengaruh terhadap performa akademik siswa.

I. Analisis dan Hasil Evaluasi *Classification XGBoost*



Gbr. 11 *Confusion Matrix XGBoost*

Training Accuracy = 0.9949 (99,49%)

Testing Accuracy = 0.8759 (87,59%).


Model *XGBoost* mampu mengklasifikasikan sebagian besar data dengan benar yang ditunjukkan oleh dominasi nilai pada diagonal utama confusion matrix. Model memperoleh training accuracy sebesar 99,49% dan testing accuracy sebesar 87,59%, sehingga menjadi model dengan performa terbaik dibandingkan *Logistic Regression* dan *Random Forest*.

	precision	recall	f1-score	support
Low	0.88	0.87	0.88	577
Medium	0.69	0.73	0.71	420
High	0.84	0.78	0.81	325
accuracy			0.81	1322
macro avg	0.80	0.80	0.80	1322
weighted avg	0.81	0.81	0.81	1322

Gbr. 12 Evaluasi *XGBoost*

Berdasarkan *classification report*, model *XGBoost* menunjukkan performa yang sangat baik pada kategori Low, Medium, dan High. Model memperoleh accuracy sebesar 87,59% dengan nilai precision, recall, dan F1-score yang tinggi., sehingga mampu mengklasifikasikan performa akademik siswa secara lebih akurat dibandingkan model lainnya.

J. Classification Model Performance Comparison



Gbr. 13 Classification Model Performance Comparison

Terlihat bahwa model *XGBoost* memiliki performa terbaik dibandingkan *Logistic Regression* dan *Random Forest*. *XGBoost* memperoleh nilai evaluasi tertinggi dengan accuracy sebesar 87,59%, sehingga dipilih sebagai model terbaik untuk klasifikasi performa akademik siswa pada penelitian ini. Hasil penelitian menunjukkan bahwa model berbasis *ensemble learning* memiliki performa yang lebih baik dibandingkan model linear. *XGBoost* mampu menangkap hubungan yang kompleks antara faktor akademik, lingkungan, dan karakteristik siswa sehingga menghasilkan akurasi yang lebih tinggi. Temuan ini menunjukkan bahwa performa akademik siswa dipengaruhi oleh kombinasi berbagai faktor yang tidak selalu bersifat linear.

K. Perbandingan Model Classification

	Model	Accuracy	Precision	Recall	F1 Score
0	XGBoost	0.8759	0.8798	0.8759	0.8768
1	Random Forest	0.8056	0.8085	0.8056	0.8066
2	Logistic Regression	0.8011	0.8033	0.8011	0.8020


Best Model : XGBoost

Gbr. 14 Perbandingan Model Classification

Model *XGBoost* dipilih sebagai model terbaik karena memperoleh nilai testing accuracy tertinggi sebesar 87,59%. sehingga lebih efektif dalam mengklasifikasikan kategori performa akademik siswa dibandingkan *Logistic Regression* dan *Random Forest*.

L. Analisis Clustering Menggunakan K-Means


1. Penentuan Jumlah Cluster Menggunakan *Elbow Method*



Gbr. 15 Clustering Elbow Method

Metode *Elbow* digunakan untuk menentukan jumlah cluster optimal pada algoritma *K-Means*. Hasil pengujian menunjukkan bahwa jumlah cluster terbaik adalah $K = 5$, sehingga data siswa dikelompokkan ke dalam lima cluster yang memiliki karakteristik berbeda

2. Analisis *Silhouette Score*



Gbr. 16 Silhouette Score

Nilai *silhouette score* digunakan untuk mengukur kualitas hasil pengelompokan data. Hasil evaluasi menunjukkan bahwa jumlah cluster optimal diperoleh pada $K = 5$ dengan nilai *silhouette score* sebesar 0,09. Nilai tersebut menunjukkan bahwa batas antar cluster tidak sepenuhnya terpisah secara tegas karena karakteristik akademik siswa cenderung bersifat kontinu. Meskipun demikian, cluster yang terbentuk masih mampu merepresentasikan pola dan karakteristik siswa yang berbeda sehingga tetap memberikan informasi yang bermanfaat untuk analisis segmentasi siswa.


3. Cluster Profile Heatmap



Gbr. 17 Cluster Profile Heatmap

Setiap cluster memiliki karakteristik yang berbeda berdasarkan nilai rata-rata fitur yang digunakan. Hal ini menunjukkan bahwa proses clustering berhasil membentuk kelompok siswa dengan profil yang berbeda.


4. K-Means Clustering Visualization (PCA)



Gbr. 18 K-Means Clustering Visualization (PCA)

Hasil clustering divisualisasikan menggunakan PCA untuk mereduksi data menjadi dua dimensi. Hasilnya menunjukkan data terbagi ke dalam 5 cluster yang relatif terpisah, sehingga *K-Means* mampu mengelompokkan siswa berdasarkan karakteristiknya dengan cukup baik.

5. Proporsi Kategori Performa Berdasarkan Cluster




Gbr. 19 Performance Category Proportion by Cluster

Setiap cluster memiliki proporsi kategori performa siswa yang berbeda. Perbedaan komposisi kategori *Low*, *Medium*, dan *High* pada masing-masing cluster menunjukkan bahwa algoritma *K-Means* berhasil mengelompokkan siswa berdasarkan karakteristik performa akademiknya.

Hasil clustering menunjukkan bahwa siswa tidak dapat dikelompokkan hanya berdasarkan nilai ujian. Beberapa cluster memiliki tingkat performa yang relatif mirip namun menunjukkan karakteristik perilaku belajar yang berbeda. Hal ini menunjukkan bahwa faktor seperti jam belajar, tingkat kehadiran, dan dukungan keluarga berperan dalam membentuk pola akademik siswa.

M. Analisis Visualisasi Data


1. Hours Studied vs Exam Score



Gbr. 20 Histogram Hours Studied vs Exam Score

Berdasarkan Gambar 20, terlihat bahwa siswa dengan jam belajar (*Hours Studied*) yang lebih tinggi cenderung memperoleh nilai ujian (*Exam Score*) yang lebih baik. Hal ini menunjukkan bahwa intensitas belajar memiliki pengaruh positif terhadap performa akademik siswa.


2. Attendance vs Exam Score



Gbr. 21 Histogram Attendance vs Exam Score

Berdasarkan Gambar 21, terlihat bahwa siswa dengan tingkat kehadiran (*Attendance*) yang lebih tinggi cenderung memperoleh nilai ujian (*Exam Score*) yang lebih baik. Hal ini menunjukkan bahwa kehadiran dalam proses pembelajaran berpengaruh positif terhadap performa akademik siswa.

3. Previous Score vs Exam Score




Gbr. 22 Histogram Previous Score vs Exam Score

Berdasarkan Gambar 22, terlihat adanya hubungan positif antara nilai sebelumnya (*Previous Scores*) dan nilai ujian (*Exam Score*). Siswa yang memiliki nilai akademik sebelumnya lebih tinggi cenderung memperoleh nilai ujian yang lebih baik. Hal ini menunjukkan bahwa *Previous Scores*

menjadi salah satu faktor yang berpengaruh terhadap performa akademik siswa.


4. Teacher Quality vs Exam Score



Gbr. 23 Histogram Teach Quality vs Exam Score

Berdasarkan Gambar 23, terlihat bahwa kualitas guru (*Teacher Quality*) memiliki hubungan dengan nilai ujian (*Exam Score*). Siswa yang mendapatkan kualitas pengajaran yang lebih baik cenderung memperoleh nilai ujian yang lebih tinggi. Hal ini menunjukkan bahwa kualitas guru merupakan salah satu faktor yang dapat mendukung peningkatan performa akademik siswa.


5. Peer influence vs Exam Score



Gbr. 24 Histogram Peer Influence vs Exam Score

Berdasarkan Gambar 24, terlihat bahwa pengaruh teman sebaya (*Peer Influence*) memiliki hubungan terhadap nilai ujian (*Exam Score*). Perbedaan tingkat pengaruh teman menunjukkan variasi nilai ujian siswa, sehingga faktor lingkungan pertemanan dapat menjadi salah satu faktor yang mempengaruhi performa akademik siswa.

6. Performance Category Distribution




Gbr. 25 Performance Category Distribution

Berdasarkan Gambar 25, terlihat bahwa sebagian besar siswa berada pada kategori *Low*. Hal ini menunjukkan bahwa mayoritas data dalam dataset memiliki tingkat performa akademik yang relatif rendah dibandingkan kategori lainnya. Perbedaan jumlah data pada setiap kategori menunjukkan adanya ketidakseimbangan distribusi kelas yang perlu diperhatikan dalam proses pelatihan dan evaluasi model machine learning.

N. Explainable AI (XAI) Menggunakan SHAP

1. SHAP Summary/Interaction Plot




Gbr. 26 Shap Interaction Plot

Fitur *Hours_Studied*, *Attendance*, dan *Parental_Involvement* memiliki interaksi dalam memengaruhi prediksi model. Sebagian besar nilai interaksi berada di sekitar nol, yang menunjukkan bahwa pengaruh masing-masing fitur lebih dominan dibandingkan interaksi antar fitur. Namun, terdapat beberapa variasi yang menunjukkan adanya hubungan antar fitur dalam menentukan performa akademik siswa.

Berdasarkan visualisasi tersebut, terlihat bahwa *Hours Studied* dan *Attendance* memiliki pengaruh paling besar terhadap hasil prediksi model. Nilai SHAP positif cenderung meningkatkan peluang siswa masuk ke kategori performa yang lebih tinggi, sedangkan nilai SHAP negatif memberikan pengaruh sebaliknya.


2. SHAP Bar Plot



Gbr. 27 Shap Bar Plot

Fitur *Attendance*, *Hours_Studied*, dan *Previous_Scores* memiliki pengaruh paling besar terhadap prediksi model. Sementara itu, fitur *Parental_Involvement*, *Tutoring_Sessions*, dan *Family_Income* menunjukkan pengaruh sedang, sedangkan fitur seperti *Gender*, *Sleep_Hours*, dan *School_Type* memiliki pengaruh yang sangat kecil.

3. SHAP Waterfall Plot



Gbr. 28 Shap Waterfall Plot

Beberapa fitur memberikan kontribusi positif maupun negatif terhadap hasil prediksi model. Fitur dengan kontribusi terbesar memiliki pengaruh paling dominan dalam menentukan kategori performa siswa. Visualisasi ini menunjukkan bagaimana setiap fitur secara individual membentuk hasil prediksi akhir yang dihasilkan oleh model *XGBoost*. Implementasi SHAP memungkinkan model tidak hanya menghasilkan prediksi, tetapi juga menjelaskan faktor-faktor yang memengaruhi hasil prediksi tersebut. Informasi ini dapat membantu guru dan institusi pendidikan dalam memahami penyebab rendahnya performa akademik siswa sehingga intervensi yang diberikan dapat lebih tepat sasaran.

Analisis SHAP memperkuat hasil klasifikasi dengan menunjukkan bahwa faktor yang paling berpengaruh terhadap prediksi berasal dari perilaku akademik siswa. Dominasi variabel *Hours Studied* dan *Attendance* mengindikasikan bahwa peningkatan kebiasaan belajar dan kedisiplinan memiliki potensi yang lebih besar dalam meningkatkan performa akademik dibandingkan faktor-faktor yang bersifat demografis.

V. IMPLEMENTASI SISTEM (STREAMLIT)

Implementasi sistem dilakukan menggunakan framework *Streamlit* untuk membangun aplikasi web interaktif berbasis *machine learning*. Aplikasi ini memungkinkan pengguna untuk melakukan analisis data, melihat hasil klasifikasi, melakukan *clustering*, serta melakukan prediksi performa siswa secara langsung. Selain itu, aplikasi juga dilengkapi dengan fitur *Explainable AI* yang memberikan penjelasan terhadap hasil prediksi model. Sistem ini dirancang agar mudah digunakan oleh pengguna non-teknis seperti guru atau tenaga pendidik, sehingga hasil analisis dapat dimanfaatkan secara praktis dalam pengambilan keputusan di bidang pendidikan.

Implementasi sistem merupakan tahap akhir dalam metodologi CRISP-DM yang bertujuan menerapkan model *machine learning* yang telah dibangun ke dalam sebuah aplikasi yang dapat digunakan secara langsung oleh pengguna. Pada penelitian ini, implementasi dilakukan menggunakan framework *Streamlit* berbasis Python untuk membangun aplikasi web interaktif yang mampu melakukan analisis data, klasifikasi performa siswa, *clustering*, *Explainable Artificial Intelligence* (XAI), dan prediksi performa siswa. Aplikasi dikembangkan berdasarkan model terbaik yang diperoleh pada tahap evaluasi, yaitu algoritma *XGBoost* dengan tingkat akurasi sebesar 87,59%.

Selanjutnya, aplikasi yang dikembangkan terdiri atas beberapa halaman utama, yaitu *Home*, *Dataset Overview*, *Classification*, *Clustering*, *Explainable AI*, *Prediction*, dan *About*. Masing-masing halaman memiliki fungsi yang berbeda dalam mendukung proses analisis dan prediksi performa siswa.

A. Arsitektur Aplikasi

Aplikasi dibangun menggunakan framework *Streamlit* yang terintegrasi dengan model *machine learning* hasil pelatihan. Pengguna dapat mengakses sistem melalui antarmuka web untuk melihat informasi dataset, hasil klasifikasi, hasil *clustering*, interpretasi model, serta melakukan prediksi performa siswa. Data yang telah melalui tahap *preprocessing* diproses menggunakan model *XGBoost* dan K-Means yang kemudian menghasilkan berbagai bentuk keluaran berupa visualisasi, analisis, dan prediksi. Strukturalamannya sendiri yaitu:


Modul	Fungsi
Home	Menampilkan ringkasan sistem dan hasil

	utama
Dataset Overview	Menampilkan karakteristik dataset
Classification	Menampilkan hasil evaluasi model
Clustering	Menampilkan hasil segmentasi siswa
Explainable AI	Menampilkan interpretasi SHAP
Prediction	Melakukan prediksi performa siswa
About	Menampilkan informasi proyek

Tabel. 2 Struktur Model Aplikasi

B. Implementasi Halaman *Home Student Performance Analysis & Prediction System*


Halaman *Home* merupakan halaman utama aplikasi yang menampilkan ringkasan hasil penelitian secara keseluruhan. Informasi yang ditampilkan meliputi jumlah data, jumlah atribut, model terbaik, tingkat akurasi, serta rangkuman hasil klasifikasi, clustering, dan analisis *Explainable AI*. Halaman ini memberikan gambaran umum mengenai sistem sebelum pengguna mengakses modul lainnya.



Gbr. 29 Halaman *Home Student Performance Analysis & Prediction System*

C. Implementasi Halaman *Dataset Overview*


Halaman *Dataset Overview* digunakan untuk menampilkan informasi dasar mengenai dataset yang digunakan dalam penelitian. Informasi yang disajikan meliputi jumlah data, jumlah atribut, statistik deskriptif, distribusi data, serta hubungan antar variabel melalui berbagai visualisasi. Halaman ini membantu pengguna memahami karakteristik data sebelum proses pemodelan dilakukan.



Gbr. 30 Halaman *Dataset Overview*

D. Implementasi Halaman *Classification Analysis*


Halaman *Classification* menampilkan hasil evaluasi model klasifikasi yang digunakan, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost*. Pengguna dapat melihat perbandingan performa model, *confusion matrix*, serta *feature importance*. Berdasarkan hasil evaluasi, *XGBoost* dipilih sebagai model terbaik dengan akurasi sebesar 87,59%.



Gbr. 31 Halaman *Classification Analysis*

E. Implementasi Halaman *Clustering Analysis*


Halaman *Clustering* menampilkan hasil segmentasi siswa menggunakan algoritma *K-Means*. Visualisasi yang disediakan meliputi *Elbow Method*, *Silhouette Score*, *Cluster Heatmap*, dan *PCA Visualization*. Halaman ini membantu mengidentifikasi kelompok siswa dengan karakteristik akademik yang berbeda.



Gbr. 32 Halaman *Clustering Analysis*

F. Implementasi Halaman *Explainable AI - SHAP Analysis*


Halaman *Explainable AI* mengimplementasikan metode *SHAP* untuk menjelaskan hasil prediksi model *XGBoost*. Visualisasi yang ditampilkan meliputi *SHAP Feature Importance*, *SHAP Summary Plot*, dan *SHAP Waterfall Plot*. Melalui halaman ini, pengguna dapat memahami faktor-faktor yang paling berpengaruh terhadap performa akademik siswa.



Gbr. 33 Halaman *Explainable AI - SHAP Analysis*

G. Implementasi Halaman *Students Performance Prediction*


Halaman *Prediction* digunakan untuk melakukan prediksi performa akademik siswa secara *real-time*. Pengguna dapat memasukkan data siswa melalui formulir yang tersedia, kemudian sistem akan menghasilkan prediksi kategori *Low*, *Medium*, atau *High* beserta tingkat kepercayaan dan rekomendasi yang sesuai.



Gbr. 34 Halaman *Student Performance Prediction*

H. Implementasi Halaman *About*

Halaman *About* berisi informasi mengenai latar belakang proyek, dataset yang digunakan, metodologi penelitian, hasil yang diperoleh, serta teknologi yang digunakan dalam pengembangan aplikasi. Halaman ini berfungsi sebagai dokumentasi singkat dari keseluruhan sistem yang dibangun.



Gbr. 35 Halaman *About*

I. Implikasi Hasil Penelitian

Hasil penelitian menunjukkan bahwa faktor perilaku akademik seperti *Hours Studied* dan *Attendance* memiliki pengaruh yang lebih besar dibandingkan *sebagian* besar faktor demografis. Temuan ini menunjukkan bahwa peningkatan kualitas pembelajaran dapat difokuskan pada pembentukan kebiasaan belajar yang baik dan peningkatan tingkat kehadiran siswa. Selain itu, hasil clustering menunjukkan bahwa siswa memiliki karakteristik yang beragam sehingga pendekatan pembelajaran yang bersifat personal dapat menjadi alternatif untuk meningkatkan hasil belajar. Implementasi sistem yang dibangun juga menunjukkan bahwa pendekatan machine learning dapat digunakan sebagai alat pendukung pengambilan keputusan berbasis data pada institusi pendidikan.

J. Keterbatasan Penelitian

Penelitian ini masih memiliki beberapa keterbatasan. Dataset yang digunakan berasal dari platform Kaggle sehingga belum tentu merepresentasikan kondisi seluruh institusi pendidikan. Selain itu, penelitian hanya menggunakan satu sumber dataset sehingga kemampuan generalisasi model masih perlu diuji pada data yang berbeda. Pada proses clustering, nilai silhouette score yang diperoleh relatif rendah yaitu sebesar 0,09 yang menunjukkan bahwa batas antar cluster tidak sepenuhnya terpisah secara tegas. Penelitian ini juga hanya membandingkan algoritma Logistic Regression, Random Forest, dan XGBoost sehingga masih terdapat peluang untuk mengeksplorasi algoritma lain pada penelitian selanjutnya.

VI. KESIMPULAN

Penelitian ini berhasil menerapkan metode *machine learning* untuk melakukan klasifikasi performa akademik siswa dan analisis pola belajar menggunakan dataset *Student Performance Factors*. Tiga algoritma klasifikasi, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost*, dibandingkan untuk menentukan model terbaik. Hasil evaluasi menunjukkan bahwa *XGBoost* menghasilkan performa tertinggi dengan nilai akurasi sebesar 87,59%, sehingga dipilih sebagai model utama dalam sistem. Selain klasifikasi, penelitian ini juga menerapkan *K-Means Clustering* yang menghasilkan lima kelompok siswa dengan karakteristik yang berbeda. Analisis *Explainable Artificial Intelligence* menggunakan *SHAP* menunjukkan bahwa *Hours Studied* dan *Attendance* merupakan faktor yang paling berpengaruh terhadap performa akademik siswa.

Model terbaik kemudian diimplementasikan ke dalam aplikasi web berbasis *Streamlit* yang menyediakan fitur analisis data, klasifikasi, clustering, interpretasi model, dan prediksi performa siswa secara interaktif. Hasil penelitian menunjukkan bahwa pendekatan *machine learning* dapat dimanfaatkan sebagai alat pendukung evaluasi dan pengambilan keputusan di bidang pendidikan berbasis data.

UCAPAN TERIMA KASIH

Terima kasih kepada Dosen pengampu mata kuliah Data Mining atas bimbingan, arahan, serta ilmu yang telah diberikan selama proses pembelajaran dan penyusunan artikel ini. Bimbingan tersebut sangat membantu dalam memahami konsep-konsep Data Mining, khususnya dalam penerapan metode *Classification* dan *Clustering* pada studi kasus nyata.

Kami juga mengucapkan terima kasih kepada teman-teman yang telah memberikan dukungan, diskusi, serta kerja sama selama pengerjaan proyek ini. Masukan dan kolaborasi yang diberikan sangat membantu dalam menyelesaikan penelitian ini dengan lebih baik.

REFERENSI

- [1] Nurkholis. (2013). Pendidikan dalam upaya memajukan teknologi. Jurnal Kependidikan, 1(1), 24–44. <https://media.neliti.com/media/publications/104343-ID-none.pdf>
- [2] Seherr, A. (2024). Student Performance Dataset. Kaggle Dataset. <https://www.kaggle.com/datasets/ayeshaseherr/student-performance>
- [3] Abiodun, O. J., & Wreford, A. I. (2024). Student's Performance Evaluation Using Ensemble Machine Learning Algorithms. *Engineering and Technology Journal*, 9(8), 4768–4775. <https://doi.org/10.47191/etj.v9i08.23>
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [5] Cortez, P., & Silva, A. (2008). Using data mining to predict secondary school student performance. *Proceedings of 5th Annual Future Business Technology Conference*. https://doi.org/10.1007/978-3-540-77226-2_82
- [6] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD Conference*. <https://doi.org/10.1145/2939672.2939785>
- [7] Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5–32. <https://doi.org/10.1023/A:1010933404324>
- [8] Hendrayani. (2020). Pendidikan sebagai upaya pengembangan potensi manusia. *Jurnal Pendidikan dan Pembelajaran*, 10(2), 45–52.

- [9] M. S. Rafsanjani, V. Suryani, And R. R. Pahlevi, "Deteksi Serangan Botnet Pada Jaringan Internet Of Things Menggunakan Algoritma Random Forest (Rf)".
- [10] Romero, C., & Ventura, S. (2010). Educational data mining: A review of the state of the art. *IEEE Transactions on Systems, Man, and Cybernetics Part C*, 40(6), 601–618.
- [11] Shahiri, A. M., Husain, W., & Rashid, N. A. (2015). A review on predicting student's performance using data mining techniques. *Procedia Computer Science*, 72, 414–422.
- [12] N. Husin, "Komparasi Algoritma Random Forest, Naïve Bayes, Dan Bert Untuk Multi-Class Classification Pada Artikel Cable News Network (Cnn)," *Infokom*, Vol. 7, No. 1, Pp. 75–84, May 2023, Doi: 10.55886/Infokom.V7i1.608.
- [13] M. Ganjirad And M. R. Delavar, "Flood Risk Mapping Using Random Forest And Support Vector Machine," *Isprs Ann. Photogramm. Remote Sens. Spatial Inf. Sci.*, Vol. X-4/W1-2022, Pp. 201–208, Jan. 2023, Doi: 10.5194/Isprs-Annals-X-4-W12022-201-2023.
- [14] I. Daniel, H. Hartono, And Z. Situmorang, "Analysis Of Machine Learning Algorithms In Predicting The Flood Status Of Jakarta City," *Icostec*, Vol. 2, No. 1, Pp. 82–87, Mar. 2023, Doi: 10.35842/Icostec.V2i1.42.
- [15] W. Hastomo, N. Aini, A. S. B. Karno, And L. M. R. Rere, "Machine Learning Methods For Predicting Manure Management Emissions," Vol. 11, No. 2, 2022.
- [16] B. Christoffer and M. Lindovsky, "Machine Learning Project Management - A Study of Project Requirements and Processes in Early Adoption." Master's thesis, Dept. Architecture and Civil Engineering, Univ., Chalmers University of Technology, Gothenburg, Sweden, 2019.
- [17] C. Schröer, F. Kruse, and J. M. Gómez, "A Systematic Literature Review on Applying CRISP-DM Process Model," *Procedia Comput. Sci.*, vol. 181, pp. 526–534, 2021. doi: <https://doi.org/10.1016/j.procs.2021.01.199>
- [18] MacQueen, J. (1967). *Some Methods for Classification and Analysis of Multivariate Observations*. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1, 281–297.
- [19] Lloyd, S. P. (1982). Least Squares Quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137. <https://doi.org/10.1109/TIT.1982.1056489>
- [20] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to linear regression analysis* (5th ed.). Wiley.

LAMPIRAN

- A. Dataset: <https://www.kaggle.com/datasets/ayeshaseherr/student-performance/data>
- B. Aplikasi Streamlit: <https://student-performance-intelligence-system-8sygkjacvzeejv6yclckj.streamlit.app/>
- C. Presentasi dan Demo Aplikasi:
 UAS Data Mining_Kelompok 12_KDD01.mp4
- D. Source Code Jupyter Notebbok dan Apps: <https://colab.research.google.com/drive/198Pa1S1JiYM9NDv49q3vnEGCyhbr8JFm?usp=sharing#scrollTo=h20LQ3adNtz4>
- E. Slide Presentasi: https://drive.google.com/file/d/1GoBhJOMS3vZ-vtZ_HAqMP8IYOoLoUHYu4/view?usp=sharing
- F. Repository Project Github: <https://github.com/nollkomaa/student-performance-in-telligence-system>